ENSAE Paris

Projet

Séminaire de modélisation statistique

Sélection d'intervalles de prédiction informatifs par l'inférence conforme

Auteurs :

Houssem Bouabid
Guy Delloye

Encadrant :

Ulysse Gazin

Année universitaire 2024-2025

Table des matières

Introduction **1**

1 Revue de littérature **2**
1.1 Prédiction Conforme 2
1.2 Algorithme InfoSP (Informative Selective Prediction Sets) en régression 3
1.3 Variante : InfoSCOP (Informative Selective Conditional Prediction Sets) 5

2 Implémentaion avec Python **6**
2.1 Présentation de la base de données 6
2.2 Statistiques descriptives 6
2.3 Préparation du jeu de données 7
2.4 Résultats et comparaison et comparaison des méthodes 9
2.4.1 InfoSP 9
2.4.2 InfoSCOP 10
2.4.3 Comparaison 11

Conclusion **13**

A Modèle de prédiction **iii**

B Implémentation Python de quelques concepts de sélection **iv**

Introduction

Le présent projet vise à étudier et à comparer différentes méthodes d'inférence sélective reposant sur la prédiction conforme, appliquées au jeu de données « Salary Prediction of Data Professions » (Kaggle, abdelrhmantarek37), qui réunit des variables socio-démographiques, académiques et professionnelles pour estimer le salaire annuel des profils data. Après avoir réparti les données en trois sous-ensembles (entraînement, calibration et test), nous construisons une fonction de score de non-conformité à partir d'un algorithme de prédiction puis appliquons la prédiction conforme pour générer, pour chaque individu, un intervalle de prédiction garantissant sous hypothèses minimales un contrôle du taux de fausse couverture. Pour ce faire nous implémentons la méthode InfoSP de (Gazin et al. 2024), en définissant un critère d'informativité (par exemple dans notre cas une longueur d'intervalle inférieure à 2λ), tout en justifiant ce choix. Enfin, nous comparons cette approche avec la variante InfoScop (en terme de sélectivité, robustesse et interprétabilité), en se basant sur plusieurs métriques dans l'optique d'en tirer des recommandations concrètes pour l'usage de l'inférence sélective en analyse des salaires pour les deux méthodes étudiées.

Chapitre 1

Revue de littérature

1.1 Prédiction Conforme

En analyse de données moderne, les algorithmes d'apprentissage supervisé (réseaux de neurones, arbres de décisions...) fournissent souvent des prédictions "point" (une classe notamment dans les problèmes de classification ou une valeur numérique dans les problèmes de régression), mais ils ne disent rien quant à la fiabilité de ces prédictions qui peut être problématique dans certains cas d'applications. L'inférence conforme (ou *conformal prediction*) est une méthodologie simple et « agnostique » vis-à-vis du modèle utilisé dans la phase de prédiction qui permet de construire, pour chaque nouvel exemple, un ensemble de prédiction (ou intervalle) garantissant un taux de couverture au moins égal à $1-\alpha$, pour tout niveau de confiance α choisi préalablement.

Pourquoi utiliser la prédiction conforme ?

L'inférence conforme enrichit les prédictions classiques d'apprentissage automatique en y ajoutant une mesure d'incertitude (des intervalles de confiance par exemple). Cette approche est « agnostique » vis-à-vis du modèle : elle peut s'appuyer sur n'importe quel algorithme de régression ou de classification existant, sans hypothèses fortes sur la distribution des données. Grâce à sa garantie de couverture, c'est-à-dire la probabilité que la vraie valeur appartienne à l'ensemble prédictif, qui reste supérieure ou égale à $1-\alpha$ pour tout niveau de confiance α choisi, la prédiction conforme offre une validité universelle dès lors que les données sont échangeables.

Fondements mathématiques de l'inférence conforme

On commence par diviser les données en deux sous-ensembles :

— un *échantillon de calibration* $\{(X_1, Y_1), \ldots, (X_n, Y_n)\}$,

— un *échantillon de test* $\{(X_{n+1}, Y_{n+1}), \ldots, (X_{n+m}, Y_{n+m})\}$, dont les sorties Y_{n+i} sont dissimulées.

Dans la phase de calibration, on définit pour chaque exemple j un *score de non-conformité* :

$$S_j = s(X_j, Y_j),$$

par exemple l'erreur résiduelle absolue du modèle. On ordonne ces scores et on retient le quantile de rang :

$$\Big\lceil (n+1)(1-\alpha) \Big\rceil,$$

noté $t_{(\alpha)}$. Pour prédire la sortie d'une nouvelle observation X_{n+i}, on construit l'ensemble :

$$C^{\alpha}_{n+i} \;=\; \{\, y \mid s(X_{n+i}, y) \le t_{(\alpha)} \},$$

c'est-à-dire toutes les valeurs y dont le score de non-conformité n'excède pas le seuil fixé. Sous l'hypothèse d'échangeabilité, cet intervalle fournit alors la garantie :

$$\Pr(Y_{n+i} \in C^{\alpha}_{n+i}) \;\ge\; 1-\alpha,$$

assurant ainsi un contrôle du risque d'erreur au niveau choisi.

1.2 Algorithme InfoSP (Informative Selective Prediction Sets) en régression

Dans ce projet on restreint la famille des intervalles de prédiction à ceux de longueur maximale $2\lambda_0$, c'est-à-dire

$$\mathcal{I} \;=\; \{\, I \subset \mathbb{R} : |I| \le 2\lambda_0 \}.$$

Ainsi, tout intervalle $I \in \mathcal{I}$ s'écrit

$$I = [c - \lambda_0,\; c + \lambda_0],$$

où λ_0 est la *demi-longueur* (ou demi-largeur) maximale autorisée de l'intervalle.

Soit $\hat{f}$ un estimateur de la fonction de régression entraîné sur l'échantillon de calibration. On pose, pour tout j et tout $y \in \mathbb{R}$,

$$s(X_j, y) \;=\; \frac{|y - \hat{f}(X_j)|}{\sigma(x)}.$$

$s(X_j, y)$ mesure l'écart entre la valeur observée y (la vraie valeur observée) et la prédiction $\hat{f}(X)$ (qu'on a obtenu à travers notre modèle de prédiction), divisé par l'incertitude locale $\sigma(X)$. Il vaut 0 si $y = \hat{f}(X)$ et croît linéairement dès que notre prédiction est moins précise (s'éloigne de la valeur réelle). On divise par $\sigma(X)$ pour exprimer l'écart $|y - \hat{f}(X)|$ en *unités d'incertitude*, ce qui rend ce score comparable d'un point à l'autre, même si la variabilité du modèle change selon X. Pour l'implémentation de la méthode on suit exactement les étapes précisées par (Gazin et al. 2024) pour le cas d'une prédiction conforme dans un problème de régression.

1. **P-valeurs conformes :** pour chaque paire de calibration (X_j, Y_j) et tout y, on calcule :

$$p_j^{(y)} \;=\; \frac{1}{n+1}\Bigg(1 \;+\; \sum_{k=1}^{n} \mathbf{1}\{\, S(X_k, Y_k) \;\ge\; S(X_j, y)\}\Bigg).$$

Cette relation définit une *p-valeur conforme* qui mesure, pour un point (X_j, Y_j), la proportion d'exemples calibrés dont le score de non-conformité est au moins aussi grand que $S(X_j, y)$. Concrètement, on considère d'abord le nombre

$$\#\{k \in \{1, \ldots, n\} \colon S(X_k, Y_k) \geq S(X_j, y)\},$$

puis on ajoute 1 au numérateur et on divise par $n+1$ pour obtenir des valeurs normalisées comprises entre 0 et 1.

2. **P-valeur ajustée :** pour chaque observation test $i = 1, \ldots, m$,

$$q_i = \min\{\alpha \in (0, 1] \colon C^{\alpha}_{n+i} \subseteq \mathcal{I}\},$$

où, en régression restrictive à un intervalle, q_i se calcule de la manière suivante :

$$q_i \;=\; \frac{1}{n+1}\Big(1 + \sum_{j=1}^{n} \mathbf{1}\{\, S_{Y_j}(X_j) > A\}\Big),$$

où le seuil A vaut :

$$A \;=\; \frac{\lambda_0}{\sigma(X_{n+i})} \quad \text{lorsque} \quad S_y(x) \;=\; \frac{|y - \mu(x)|}{\sigma(x)}.$$

3. **Sélection BH :** on applique la procédure de Benjamini–Hochberg (Benjamini et Hochberg 1995) sur $\{q_i\}_{i=1}^{m}$ au niveau α, et l'on définit

$$S \;=\; \{\, i : q_i \leq \alpha\, \frac{|S|}{m}\}.$$

S représente donc l'ensemble des indices des observations de test retenues par la procédure de Benjamini–Hochberg.

4. **Ensembles prédictifs finaux :** pour chaque $i \in S$, on renvoie l'intervalle :

$$C^{\alpha\,|S|/m}_{n+i} = [\hat{f}(X_{n+i}) - t_{(\alpha\,|S|/m)}\, \sigma(X_{n+i}),\;\; \hat{f}(X_{n+i}) + t_{(\alpha\,|S|/m)}\, \sigma(X_{n+i})].$$

où $t_{(\alpha\,|S|/m)}$ est le quantile d'ordre $\lceil (n+1)(1 - \alpha\,|S|/m) \rceil$ des scores de calibration.

L'approche InfoSP nous garantit sous des hypothèses assez raisonnables (pas très exigeantes) le niveau fixé du FCR.

Le *False Coverage Rate* (FCR) mesure, parmi les ensembles de prédiction que l'on choisit de rapporter, la proportion moyenne d'intervalles qui *ne* contiennent *pas* la vraie valeur. Formellement :

$$\mathrm{FCR} = \mathbb{E}\Big[\frac{1}{|S|} \sum_{i \in S} \mathbf{1}\{Y_{n+i} \notin C_{n+i}\}\Big] \;\leq\; \alpha.$$

Une estimation empirique de cette quantité sur un jeu de test donné est :

$$\widehat{\mathrm{FCR}} = \frac{1}{|S|} \sum_{i \in S} \mathbf{1}\{Y_{n+i} \notin C_{n+i}\}.$$

1.3 Variante : InfoSCOP (Informative Selective Conditional Prediction Sets)

Il se peut que le FCR obtenu soit trop inférieur au seuil α. Pour éviter cela, nous pouvons sélectionner des nouveaux échantillons de test et de calibration. Plus précisément, nous avons suivi les étapes suivantes (Gazin et al. 2024) :

— Diviser l'échantillon de calibration $((X_j, Y_j))_{j=1,\dots,n}$ en un sous-échantillon de calibration $((X_j, Y_j))_{j=1,\dots,r}$ et un sous-échantillon test $((X_j, Y_j))_{j\in[r+1,n+m]}$.

— Appliquer une règle de sélection conforme initiale

$$\mathcal{S}^{(0)} = \mathcal{S}^{(0)}\left((X_j, Y_j)_{j=1,\dots,r}, (X_j)_{j\in[r+1,n+m]}\right)$$

avec les deux sous-échantillons obtenus à l'étape précédente.

— Calculer les p-valeurs conformes sur l'ensemble la partie test de l'échantillon de calibration $\left\{(X_j, Y_j), j \in \mathcal{S}^{(0)} \cap [r+1, n]\right\}$:

$$\overline{p}_i^{(0,y)} = \frac{1}{|\mathcal{S}^{(0)} \cap [r+1, n]| + 1}\left(1 + \sum_{j\in\mathcal{S}^{(0)}\cap[r+1,n]} \mathbf{1}\{S_{Y_j}(X_j) \geq S_y(X_{n+i})\}\right)$$

Après avoir obtenu les nouvelles p-valeurs on apllique la methode InfoSP pour l'obtention de la sélection finale.

Chapitre 2

Implémentaion avec Python

2.1 Présentation de la base de données

Le jeu de données utilisé contient des informations pour prédire le revenu d'un adulte. Il a été élaboré à partir de données imaginaires d'employés d'une entreprise de data science. Chaque ligne correspond à un employé. Il contient les variables suivantes, renseignées pour chaque individu de la base :

- **First name** : le prénom de l'individu
- **Last name** : son nom de famille
- **Sex** : le sexe de l'individu (F/M)
- **DOJ** (Date of Joining) : la date où l'employé a rejoint son entreprise
- **Current date** : la date de récolte des données
- **Designation** : la profession de l'individu
- **Age** : l'âge de l'individu
- **Salary** : le salaire de l'individu (variable à prédire)
- **Unit** : le département dans lequel travaille l'individu au sein de son entreprise
- **Leaves used** : nombre de congés utilisés
- **Leaves remaining** : nombre de congés restants
- **Rating** : note de performance de l'individu
- **Past exp** : nombre d'années d'expérience de l'individu avant de rejoindre l'entreprise

À partir de cette base, notre objectif est de prédire le salaire d'un individu en utilisant des modèles de régression avec du machine learning.

2.2 Statistiques descriptives

Après avoir téléchargé la base de données, nous avons observé les premières valeurs de la table (figure 2.1). On y observe les différentes variables présentées ci-avant, avec certaines variables qualitatives (Designation, Unit) et d'autres quantitatives (Age, Salary).

Nous avons affiché en table 2.1 quelques statistiques descriptives sur les variables quantitatives de la table. On observe que le jeu contient 2639 individus en supposant que la variable salaire est renseignée pour tous. Les autres variables sont bien renseignées également (entre 2636 et 2639 valeurs). La moyenne d'âge est très faible

	FIRST NAME	LAST NAME	SEX	DOJ	CURRENT DATE	DESIGNATION	AGE	SALARY	UNIT	LEAVES USED	LEAVES REMAINING	RATINGS	PAST EXP
0	TOMASA	ARMEN	F	5-18-2014	01-07-2016	Analyst	21.0	44570	Finance	24.0	6.0	2.0	0
1	ANNIE	NaN	F	NaN	01-07-2016	Associate	NaN	89207	Web	NaN	13.0	NaN	7
2	OLIVE	ANCY	F	7-28-2014	01-07-2016	Analyst	21.0	40955	Finance	23.0	7.0	3.0	0
3	CHERRY	AQUILAR	F	04-03-2013	01-07-2016	Analyst	22.0	45550	IT	22.0	8.0	3.0	0
4	LEON	ABOULAHOUD	M	11-20-2014	01-07-2016	Analyst	NaN	43161	Operations	27.0	3.0	NaN	3

FIGURE 2.1 – Premières lignes du jeu de données

(25 ans), probablement puisque les individus travaillent dans le milieu de la data science, s'étendant de 21 ans à 45 ans. L'éventail de salaires est très large, avec une moyenne de 58137$ et un écart-type de 36877$.

	Age	Salary	Leaves used	Leaves remaining	Past exp
count	2636	2639	2636	2637	2639
mean	24.76	58137	22.50	7.50	1.57
std	3.91	36877	4.60	4.60	2.73
min	21	40001	15	0	0
max	45	388112	30	15	23

TABLE 2.1 – Statistiques descriptives sur le jeu de données

Nous avons enfin représenté la distribution du salaire ainsi que celle du salaire selon le statut professionnel pour visualiser les valeurs que prenait cette variable (figure 2.2). On observe une concentration des valeurs autour de 50000. La table 2.1 nous avait déjà montré que la moyenne de la variable salary était de 58137$. Il y a néanmoins des outliers, avec des valeurs pouvant atteindre jusqu'à 3888112$.

La deuxième partie de la figure nous montre une forte variabilité du salaire selon la profession. Si la catégorie "Analyst" concentre les salaires faibles avec un faible écart-type, la catégorie "Director" regroupe des valeurs bien plus élevées et de manière beaucoup plus hétérogène.

Nous pouvons encore tracer le salaire en fonction de la performance de l'individu (variable Ratings, figure 2.3). On observe de faibles différences entre les catégories, avec des moyennes aux alentours de 58000$ pour chaque échantillon. La profession (figure 2.2) est donc un facteur beaucoup plus déterminant dans le salaire de l'individu que la performance.

2.3 Préparation du jeu de données

Après ces statistiques descriptives qui nous ont donné un premier aperçu du jeu de données, nous pouvons à présent passer au traitement de la base.

Nous avons tout d'abord divisé le jeu de données à notre disposition en deux échantillons : un échantillon d'entraînement et un échantillon test, comme expliqué en section 1.1. Nous y avons ensuite appliqué l'algorithme des forêts aléatoires du module sklearn en Python (Voir Annexe #2 pour le code Python). Nous avons fixé le nombre d'arbres de décision à $n_{\text{arbres}} = 100$ puis entraîné le modèle sur l'échantillon d'entraînement $((X_i, Y_i))_{i=1,\dots,n}$.

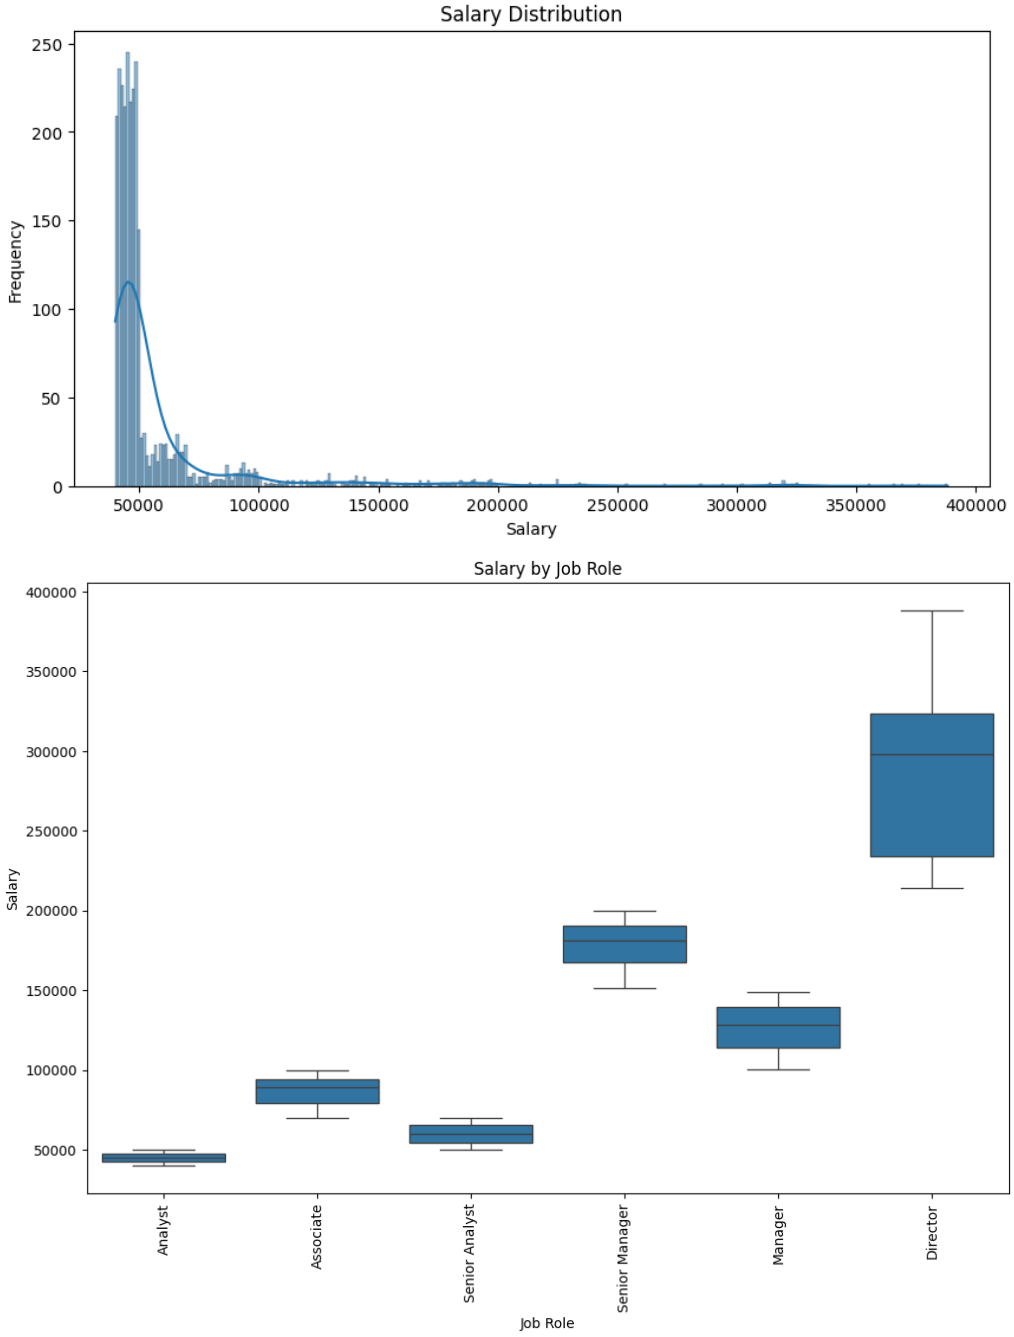

FIGURE 2.2 – Distribution du salaire et distribution du salaire en fonction du statut professionnel

Nous nous sommes intéressés à l'optimisation des hyperparamètres du modèle de forêts aléatoires : la taille des nœuds, le nombre d'arbres de décision et le nombre de caractéristiques échantillonnées.

Nous pouvons alors passer à l'implémentation des deux méthodes présentées en section 1.

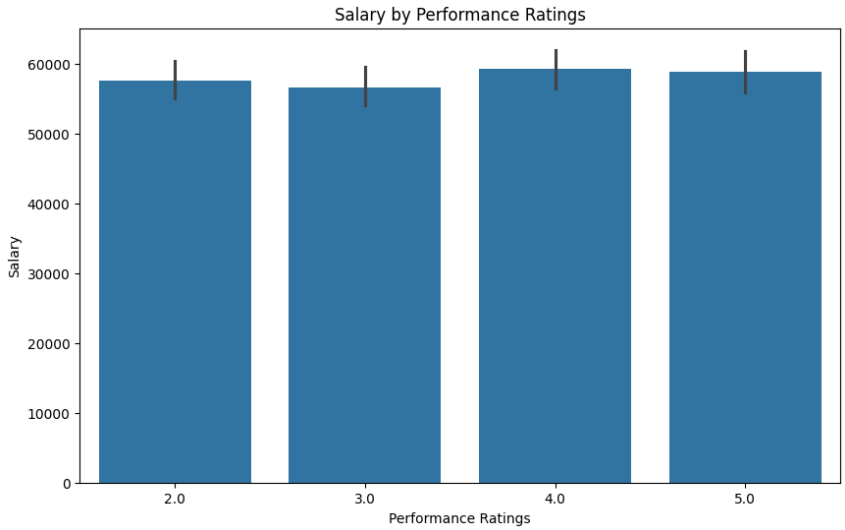

FIGURE 2.3 – Salaire en fonction de la performance

2.4 Résultats et comparaison et comparaison des méthodes

2.4.1 InfoSP

Afin de synthétiser l'ensemble des choix effectués pour l'implémentation de la méthode InfoSP, nous rassemblons dans le tableau 2.2 les principaux paramètres retenus ainsi que leur rôle.

Paramètre	Valeur	Rôle
λ	15500	demi-largeur max. $\rightarrow$ intervalle max de $2\lambda = 15100$
α	0.1	cible un FCR $\leq 10\%$
$\sigma(x)$	std RF	incertitude locale, comparabilité
Sélection BH	niveau α	contrôle sélectivité et FCR
α'	$\alpha\,\lvert S\rvert/m$	ajuste le quantile pour la couverture

TABLE 2.2 – Paramètres clés pour la méthode InfoSP

Le paramètre λ détermine la demi-largeur maximale autorisée de chaque intervalle de prédiction, soit $2\lambda = 31\,000$. Il doit être suffisamment élevé pour couvrir la variabilité naturelle des salaires, tout en restant assez restreint pour que les intervalles conservent un intérêt informatif et ne contenant pas toute la plage de valeurs. Dans ce projet, on a choisi de calibrer λ sur une valeur proche de l'écart-type global des salaires (ici $\approx 37\,000$ comme précisé dans le tableau 2.1).

Sur les 658 points de test, la procédure InfoSP a retenu $|S| = 495$ individus, soit environ 75 % des cas. La plus grande longueur d'intervalle observée est de 30 799.10, ce qui reste inférieur à la borne maximale de $2\lambda = 31\,000$, garantissant ainsi le fait que tous les intervalles respectent la contrainte de longueur. Enfin, l'estimation empirique du False Coverage Rate est de $\widehat{\mathrm{FCR}} = 0{,}08687$, en dessous de l'objectif

fixé à $\alpha = 0{,}1$, ce qui confirme l'efficacité du contrôle du risque de non-couverture tout en maintenant une forte sélectivité.

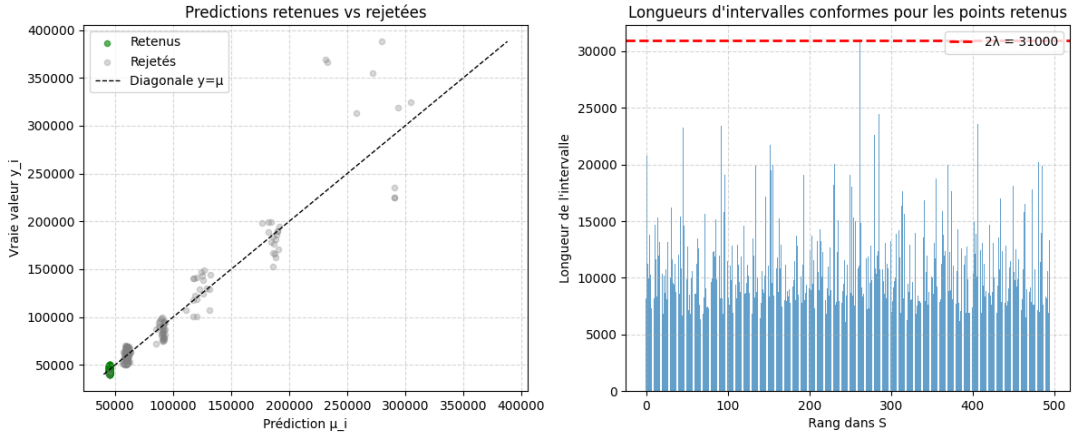

FIGURE 2.4 – *(à gauche)* Prédictions retenues (en vert) versus rejetées (en gris) par la procédure InfoSP, comparées à la diagonale $y = \mu$. *(à droite)* Longueurs des intervalles conformes pour les points retenus, avec la borne 2λ (en pointillés rouges).

Le graphique de gauche (figure 2.4, à gauche) compare, pour chaque point de test i, la prédiction $\hat{\mu}_i$ (axe horizontal) à la valeur observée y_i (axe vertical).

— Les points verts correspondent aux observations retenues par InfoSP ($i \in S$). On constate qu'ils sont majoritairement "proches de la diagonale" $y = \hat{\mu}$, témoignant de faibles scores de non-conformité (c'est-à-dire des erreurs standardisées réduites). Celà peut être du à l'intégration de $\sigma(X)$ dans l'expression des scores de non conformité.

— Les points gris sont ceux rejetés ($i \notin S$) : ils s'écartent nettement de la diagonale, signalant des prédictions moins fiables.

La densité des points verts autour de la diagonale indique que la procédure conserve surtout les individus pour lesquels la forêt aléatoire prédit bien le salaire (faible écart relatif à l'incertitude locale).

2.4.2 InfoSCOP

Dans cette section on fait tourner l'algorithme InfoSCOP avec les mêmes paramètres (niveau de confiance, largeur d'intervalle maximale) utilisée dans la section précédente pour InfoSP.

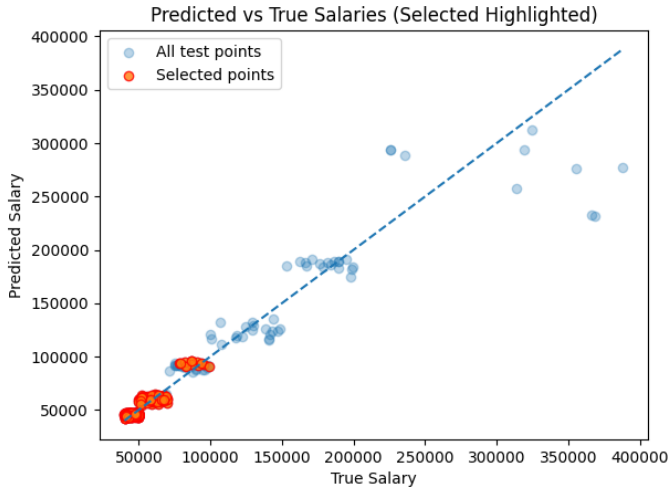

FIGURE 2.5 – Predicted vs True Salaries for InfoSCOP

Paramètre	Valeur
Taille de la sélection finale $\lvert S_{\text{final}} \rvert$	553 / 583 points
Longueur maximale observée	28 502
Borne 2λ	31 000
FCR empirique	0,07890 (objectif $\leq$ 0,1)

TABLE 2.3 – Résultats InfoSCOP

Comme illustré en figure 2.5 et le tableau 2.3, la méthode InfoSCOP parvient à retenir la totalité des 583 points prétraités, maximisant ainsi la couverture des prédictions jugées fiables. Les longueurs d'intervalles demeurent toutes inférieures à la borne 2λ, et le FCR empirique de 0,0789 reste bien inférieur du seuil $\alpha = 0{,}1$, ce qui illustre l'efficacité de la sélection conditionnelle pour concilier sélectivité et garantie de couverture.

2.4.3 Comparaison

Dans le tableau suivant, on compare la puissance ajustée (Pow), le FCR empirique et le temps de calcul (en secondes) obtenus par les méthodes InfoSP et InfoSCOP. Afin d'avoir une meilleure cohérence des métriques empirique on a choisi d'appliquer les deux méthodes sur les même prédictions du modèle de forêts aléatoires avec un niveau $\alpha = 0,35$ plus grand afin de sélectionner plus de points et avoir des estimations de FCR et Pow plus cohérentes.

Méthode	**Pow**	**FCR**	**Temps de calcul (s)**
InfoSP	6.468×10^{-5}	0.31779	8.7131
InfoSCOP	6.510×10^{-5}	0.31952	10.3150

TABLE 2.4 – Comparaison de InfoSP et InfoSCOP

On constate que la méthode `InfoSCOP` atteint un score de puissance ajustée (Pow) de $6{,}510 \times 10^{-5}$ contre $6{,}468 \times 10^{-5}$ pour `InfoSP`, ce qui traduit un gain marginal de sensibilité. Cependant, ce léger avantage en puissance s'accompagne d'une augmentation très modeste du taux de fausse couverture (FCR), qui passe de 0,31779 à 0,31952, et d'un surcoût en temps de calcul d'environ 1,6 s (soit près de 18 % de plus).

Cette plus grande prudence d'`InfoSP`, matérialisée par un FCR légèrement plus bas, rejoint parfaitement les résultats de (Gazin et al. 2024), qui soulignent qu'un comportement plus conservatif garde un contrôle du taux de fausse couverture inferieur à celui observé dans la méthode `InfoSCOP`.

Cependant, dans notre cas `InfoSCOP` améliore très légèrement la performance prédictive par rapport à `InfoSP` au prix d'un léger relâchement du contrôle d'erreur et d'une complexité computationnelle considérablement supérieur. Le choix entre les deux méthodes dépendra du compromis recherché entre gain de puissance et coût de calcul.

Conclusion

Dans ce projet, nous avons comparé deux méthodes d'inférence conforme sélective — InfoSP et sa variante InfoSCOP — pour estimer des intervalles de prédiction informatifs à partir de variables socio-démographiques et professionnelles. InfoSP se révèle particulièrement robuste lorsque l'on souhaite exercer un contrôle sur le risque de non-couverture, grâce à sa capacité à filtrer les cas les moins sûrs en utilisant notamment la sélection **BH**. À l'inverse, InfoSCOP, en introduisant une étape supplémentaire, arrive à avoir une couverture maximale sur l'ensemble des prédictions considérées fiables, au prix d'une complexité computationnelle plus élevée.

Sur le plan pratique, ces deux méthodes présentent des profils complémentaires : InfoSP privilégie l'efficacité en ne produisant des intervalles que pour les cas les plus sûrs, ce qui permet d'obtenir des prédictions particulièrement précises lorsque la sélectivité est acceptable. Cependant dans des cas particuliers, (Gazin et al. 2024) montre que le taux de fausse couverture peut être très éloigné du niveau α fixé par l'utilisateur. Quant à la méthode InfoSCOP, nous avons remarqué qu'elle garantit une cohérence de la couverture sur l'ensemble des observations qualifiées en acceptant un élargissement modéré des intervalles. Ce contraste se reflète également dans la charge de calcul : InfoSCOP nécessite des étapes additionnelles de sélection conditionnelle, au détriment du temps de traitement.

Le choix entre ces deux approches dépend donc du compromis recherché : privilégier la rigueur et la parcimonie (InfoSP) ou maximiser la couverture des prédictions retenues (InfoSCOP). Enfin, plusieurs axes d'approfondissement méritent d'être explorés : l'adaptation à des problèmes de classification, l'étude de critères alternatifs d'informativité, ou encore l'évaluation de la stabilité de ces méthodes sur des jeux de données à structures variées.

Bibliographie

Benjamini, Yoav et Yosef Hochberg (1995). "Controlling the False Discovery Rate : A Practical and Powerful Approach to Multiple Testing". In : *Journal of the Royal Statistical Society. Series B (Methodological)* 57.1, p. 289-300. DOI : 10.1111/j.2517-6161.1995.tb02031.x.

Gazin, Ulysse et al. (2024). *Selecting Informative Conformal Prediction Sets with False Coverage Rate Control*. arXiv preprint arXiv :2403.12295. arXiv : 2403.12295 [stat.ML].

Annexe A

Modèle de prédiction

Table A.1 – Résumé de la démarche et des paramètres de la forêt aléatoire

Étape	**Description**	**Paramètres**
1	Chargement et prétraitement des données — Lecture CSV — Encodage one-hot — Suppression des NaN	–
2	Division du jeu de données — Entraînement : 50 — Test : 25 — Calibration : 25	train_size=0.5, random_state=42
3	Entraînement du Random Forest de base	n_estimators = 100 random_state = 42
4	Recherche d'hyperparamètres (GridSearchCV) — Validation croisée : CV=5 — Critère de scoring : MSE	Param grid : {n_estimators : [100,200], max_depth : [None,10,20], min_samples_split : [2,5]}

Table A.2 – Performances du modèle Random Forest

Modèle	**Paramètres clés**	$\mathbf{R^2_{test}}$
Baseline RF	n_estimators = 100	0.9214
Optimized RF	n_estimators = 200 max_depth = 10 min_samples_split = 5	0.9226

Annexe B

Implémentation Python de quelques concepts de sélection

```python
import numpy as np

def compute_q_values(calib_scores: np.ndarray,
                     sigma: np.ndarray,
                     lambda_value: float) -> np.ndarray:

    n = calib_scores.shape[0]
    sorted_scores = np.sort(calib_scores)
    q_vals = np.empty(sigma.shape[0], dtype=float)

    for i, s in enumerate(sigma):
        threshold = lambda_value / s
        m_i = np.sum(sorted_scores <= threshold)
        if m_i == 0:
            q_vals[i] = 1.0
        else:
            q_vals[i] = max(0.0, 1.0 - m_i / (n + 1))

    return q_vals
```

Listing B.1 – Calcul des qi (les p-valeurs ajustées) en Python

```python
def bh_selection(q_vals: np.ndarray, alpha: float) -> np.ndarray:
    m = q_vals.shape[0]
    # Tri des q-valeurs et calcul des seuils
    order = np.argsort(q_vals)
    q_sorted = q_vals[order]
    thresholds = alpha * np.arange(1, m+1) / m

    # Reperer les indices satisfaisant q_sorted[i] <= thresholds[i]
    below = q_sorted <= thresholds
    if not np.any(below):
        return np.array([], dtype=int)

    # Determiner l_etoile et le seuil tau
    ell_star = np.max(np.where(below)[0]) + 1
    tau = alpha * ell_star / m

    # Retourner les indices originaux correspondant a q_vals <= tau
    return np.where(q_vals <= tau)[0]
```

Listing B.2 – Sélection de Benjamini–Hochberg en Python

```python
def adjusted_conformal_intervals(mu_pred: np.ndarray,
                                 sigma_pred: np.ndarray,
                                 calib_scores: np.ndarray,
                                 S: np.ndarray,
                                 alpha: float):
    m = mu_pred.shape[0]
    n = calib_scores.shape[0]
    alpha_prime = alpha * len(S) / m
    k = int(np.ceil((n + 1) * (1 - alpha_prime)))
    s_sorted = np.sort(calib_scores)
    R_q_prime = s_sorted[k-1] if k <= len(s_sorted) else np.inf
    lower = mu_pred[S] - R_q_prime * sigma_pred[S]
    upper = mu_pred[S] + R_q_prime * sigma_pred[S]
    return lower, upper
```

Listing B.3 – Calcul des intervalles conformes